

airbnb

Nicklas Thegerström

Emil Sjökvist

Fredrik Käll

Gruppprojekt

DATASET: INSIDE AIRBNB, STOCKHOLM
LISTINGS

4 955 LISTNINGAR, 79 KOLUMNER

NEURALA NÄTVERK FÖR ATT PREDIKTERA PRIS



STOCKHOLM · AIRBNB · TENSORFLOW

Vad är en bostad värd?

Prisprediktion för Airbnb i Stockholm med neurala nätverk

— och frågan: *hur mycket avslöjar bara orden i en annons?*

3 027

Listings kvar efter
datarening

79

variabler

26 %

rel. fel (bästa)

Vår databerättelse i sex steg



1. Datan & EDA

Vad innehåller datasetet och hur hänger variablerna ihop?



2. Bara text

Hur långt kommer vi med enbart hyresvärdarnas fritext?



3. Text + struktur

Vad tillför antal rum, läge och recensioner?



4. Optimering

Kan Grid Search pressa modellen längre?



5. Var felar den?

Geografisk analys av modellens träffsäkerhet.



6. Affärsvärde

Hur kan ett företag faktiskt använda detta?

Datasetet: Airbnb-annonser i Stockholm

Källa: Inside Airbnb — offentliga annonser för Stockholm.

Vi förutsäger **pris per natt (SEK)** utifrån två sorters data:

Strukturerad data

Antal rum, badrum, kapacitet, läge (koordinater), recensionspoäng, tillgänglighet, värdinfo

Ostrukturerad text

name, description, amenities, neighborhood_overview, host_about — fem fritextfält

Snabbfakta

3 027

annonser efter rensning


1 370 SEK

medianpris per natt

Topp 5 %

dyraste ströks (stabilare träning)

Vad driver priset? Relationer i datan



Storlek styr mest

Kapacitet och antal sovrum har starkast samband med pris.



Läget kodas geografiskt

Innerstaden är tydligt dyrare — koordinater bär lägesinfo.



Ett multi-faktor-problem

Ingen enskild variabel dominerar — många bidrar lite.

Två pipelines, samma typ av nätverk

Pipeline 1 — Bara text

- 5 fritextfält → TF-IDF (ord blir siffror)
- 500 text-features totalt
- Sequential-nätverk (Dense + Dropout + ReLU)
- Output: 1 neuron, linjär = regression

Frågan: hur mycket bär orden ensamma?


Pipeline 2 — Allt

- Samma text-features + 32 numeriska
- 4 kategoriska (stadsdel, rumstyp ...)
- Totalt 536 features
- Identisk nätverksarkitektur

Frågan: vad tillför strukturerad data?

RESULTAT

Varje steg sänker felet



0.61

R^2 för bästa modellen


förklarar 61 % av prisvariationen

46 % lägre fel än att gissa medelvärdet

Texten ensam klarar redan R^2 0.45 — orden bär mycket prisinfo

Vilka ord hänger ihop med priset?

Skillnad i medelpris när ordet förekommer (vs inte):




Orden är proxies

"family" betyder inte att ordet är magiskt — det signalerar **större bostäder**.

Modellen läser alltså hyresvärdens marknadsföring och **härleder storlek, läge och standard** ur orden.

Paradoxen: stark text — men låg importance?

Feature importance i full modell



Informations-redundans

Texten ensam når R^2 0.45 — ändå står den bara för 16 % av importance i den fulla modellen.

Varför? Texten beskriver **samma saker** som siffrorna: storlek, läge, standard — bara med ord.

När modellen har exakta siffror föredrar den dem. Texten blir en reservkälla.

Hur bra kan modellen bli?



Grid Search gav ~0

64 arkitekturer testades. Förbättringen låg inom statistiskt brus — vår modell var redan nära optimum.



OLS var nästan lika bra

En enkel linjär regression nådde R^2 0.56. För tabelldata är enkla modeller starka konkurrenter.



Datan är taket

3 027 rader är litet för djupinlärning. Mer data — inte fler lager — krävs för nästa kliv.

Var träffar modellen — och var missar den?

Stockholm — prediktionsfel per annons



● Litet fel (<250 kr)

● Medel (250–750)

● Stort fel (>750)



Felen klustrar centralt

De största missarna ligger i innerstaden, där premium-värdar tar ut ett påslag modellen inte kan se i datan.

Ex: en SoFo-lägenhet med verkligt pris 2 703 kr — modellen gissade ~1 834 kr.

Varför är detta värdefullt för företaget?



Prisrekommendation

Nya värdar får direkt ett datadrivet förslag: "din bostad borde kosta ~1 200 kr/natt."



Hitta felprissatta annonser

Flagga listings där priset avviker kraftigt från modellen — risk för låg beläggning eller missade intäkter.



Optimera beskrivningar

Visa värdar vilka ord som hänger ihop med högre pris — t.ex. lyfta fram "family" om det stämmer.



Marknadsinsikt

Felkartan visar var prissättningen är mest "mänsklig" — underlag för var rådgivning behövs.

Tre saker vi tar med oss

1

Orden bär mer än man tror

Bara hyresvärdarnas fritext förklarar 45 % av prisvariationen — de marknadsför sig på ett sätt som speglar priset.

2

Rätt verktyg för rätt data

På 3 000 rader är enkla modeller (OLS) nästan lika bra. Deep Learning lönar sig först vid mer data eller bild/text i centrum.

3

Modellen pekar på det mänskliga

Där modellen missar mest — centrala premiumannonser — är där skicklig, mänsklig prissättning gör störst skillnad.