

Återskapa saknade värden med en autoencoder

En metod för imputering av data med neurala nätverk

Av: Fredrik Käll, Emil Sjökvist, Nicklas Thegerström

Problemet: Saknade värden

Data är en av de viktigaste byggstenarna inom artificiell intelligens och maskininlärning. I verkliga datamängder saknas dock ofta vissa observationer eller variabelvärden.

Saknade värden kan bland annat bero på:

- Mätfel eller tekniska problem
- Ofullständiga enkätsvar
- Fel vid insamling eller lagring
- Att information aldrig registrerades

Om problemet inte hanteras kan det försämra både analysen och modellens prestanda.

Traditionella lösningar

Det finns flera vanliga sätt att hantera saknade värden:

- Ta bort rader med saknade värden
- Utesluta hela variabler
- Ersätta med medelvärde eller median
- Använda närmaste grannar, exempelvis KNN
- Använda en maskininlärningsmodell för att uppskatta värdena

Att ta bort data innebär risk för informationsförlust. Enkla ersättningsmetoder bevarar mängden data, men tar ofta inte hänsyn till komplexa samband mellan variablerna.

Datamängd: California Housing

I projektet använder vi datamängden **California Housing** från Scikit-learn.

- Datamängden innehåller:
- 20 640 observationer
- 8 numeriska inmatningsvariabler
- information om bostadsområden i Kalifornien

Datamängden saknar ursprungligen inga värden. Därför kan vi själva maskera värden och sedan jämföra modellens uppskattningar med de verkliga värdena.