



STEAM®

SUPERVISED MACHINE LEARNING MED DECISION TREES

Steam Data

(Steam Store Games Dataset)



Nicklas
Thegerström



Emil
Sjökvist



Fredrik
Käll

Action

RPG

Indie

Strategy

Adventure

Simulation

Multiplayer

Open World

Survival

Story Rich

Atmospheric



FRÅGESTÄLLNING

Kan Steam-metadata förutsäga positivt användarmottagande?

STEAM-METADATA

TAGS

Action RPG Indie
Multiplayer Strategy
Adventure Survival ...

CATEGORIES

Single-player PvP
Multi-player Steam Achievements
Co-op Full Controller Support
...

PREDIKTION



SUCCESS
(POSITIVT
ANVÄNDARMOTTAGANDE)



Höga recensioner
Högt engagemang
Starkt mottagande

VS



NOT SUCCESS
(LÅGT
ANVÄNDARMOTTAGANDE)



Låga recensioner
Lågt engagemang
Svagt mottagande



DATASET

Presentation av datan



~95 000 spel

Antal spel i rådatasetet innan rensning



Steam metadata & reviews

Information om spel, community-features och recensioner från Steam



Genres, categories & tags

Kategoriska variabler som beskriver spelens innehåll och egenskaper



47 ursprungliga kolumner

Både numeriska och kategoriska features



DATAFRAME ÖVERSIKT (df.info())

```
df.info()
RangeIndex: 94948 entries, 0 to 94947
Data columns (total 47 columns):
#   Column              Non-Null Count  Dtype
---  -
0   appid               94948 non-null  int64
1   name                94946 non-null  object
2   release_date        94948 non-null  object
3   required_age        94948 non-null  int64
4   price               94948 non-null  float64
...
45  languages            94948 non-null  object
46  ccu                  94948 non-null  int64
dtypes: float64(1), int64(13), object(1), str(32)
memory usage: 34.0+ MB
```

STEAM TAGS (EXEMPEL)

tags	pct_pos_total	num_reviews_total	pct_pos_recent	num_reviews_recent
{'FPS': 90857, 'Shooter': 65397, 'Multiplayer': 52862, 'Action': 50316, ...}	86	8632939	82	96473
{'Survival': 14838, 'Shooter': 12727, 'Battle': 10935, 'Multiplayer': 9770, ...}	59	2513842	68	16720
{'Free to Play': 59933, 'MOBA': 20158, 'Multiplayer': 15518, 'Strategy': 12022, ...}	81	2452595	80	29366
{'RPG': 47348, 'Open World': 39432, 'Adventure': 36762, 'Fantasy': 32660, ...}	93	1772153	90	32666
...	...	...	...	...

Datastädning

Vi rensar bort spel utan giltig review-data och spel med för få recensioner för att minska brus och förbättra datakvaliteten.



Steg 1: Ta bort spel utan giltig review-data

```
df_model = df[df["pct_pos_total"] != -1].copy()
after_reviews = len(df_model)

# Tar bort spel där pct_pos_total == -1 (ingen giltig review-data)
```



Steg 2: Ta bort spel med färre än 50 reviews

```
df_model = df_model[df_model["num_reviews_total"] >= 50].copy()
after_min_reviews = len(df_model)

# Tar bort spel med färre än 50 totala recensioner
```

Datasetets storlek före och efter cleaning



Före cleaning

94,948 spel



Efter borttagning av -1 reviews

55,373 spel



Efter filtering (<50 reviews bort)

29,241 spel

Totalt borttagna spel

65,707 spel (69.1%)

```
# Utskrift av antal spel före och efter cleaning
print(f"Före cleaning: {before_cleaning},,} spel")
print(f"Efter borttagning av -1 reviews: {after_reviews},,} spel")
print(f"Efter filtering (<50 reviews bort): {after_min_reviews},,} spel")
```

```
Före cleaning: 94,948 spel
Efter borttagning av -1 reviews: 55,373 spel
Efter filtering (<50 reviews bort): 29,241 spel
```


Skapa klasser & välj features


Vi skapar en binär målvariabel (success) baserat på andelen positiva reviews och väljer ut relevanta features för modellerna.

1. Skapa målvariabel (binär klassificering)

```
df_model["success"] = df_model["pct_pos_total"] >= 85
```

- Successful (1): minst 85% positiva reviews
- Not Successful (0): mindre än 85% positiva reviews

2. Fördelning av target (efter datarening)



3. Features vi använder

```
features = [  
    "price",  
    "required_age",  
    "dlc_count",  
    "achievements",  
    "windows",  
    "mac",  
    "linux",  
    "genres",  
    "categories",  
    "tags"  
]
```



Kategoriska variabler
genres, categories, tags



One-hot encoding
Konverteras till numeriska dummy-variabler för att användas i modellerna.

4. Modeller vi testar



Random Forest

Robust mot outliers och fungerar bra med blandade features.



XGBoost

Gradient boosting som ofta ger hög prestanda på tabulära data.



Utvärdering

Precision, Recall, F1-score och ROC-AUC

6 FEATURE ENGINEERING

Från text till dummy-variabler

Genres, categories och tags är lagrade som listor/dictionaries.

Vi transformerar dem till binära (0/1) variabler så att modellerna kan använda dem.

1 Rå data (exempel)

Genres som listor

```
df_model["genres"].head()

0    ['Action', 'Free To Play']
1    ['Action', 'Adventure',
     'Massively Multiplayer...']
2    ['Action', 'Strategy', 'Free To Play']
3    ['Action', 'Adventure']
4    ['Action']

Name: genres, dtype: str
```

2 Transformation

MultiLabelBinarizer

```
from sklearn.preprocessing import
MultiLabelBinarizer

mlb_cat = MultiLabelBinarizer()

categories_encoded = pd.DataFrame(
    mlb_cat.fit_transform(df_model["categories"]),
    columns=mlb_cat.classes_,
    index=df_model.index
)
```

3 Resultat (exempel)

Binära (0/1) variabler

Racing	Sexual Content	Simulation	Strategy	Utilities	Video Production	Violent ...
0	0	0	1	0	0	0 ...
1	0	1	0	0	0	0 ...
0	0	1	1	0	0	0 ...
0	0	1	1	0	0	0 ...
0	0	0	0	0	0	0 ...
0	0	0	0	0	0	0 ...
0	0	1	0	0	0	0 ...
0	0	0	1	0	0	0 ...
...	...	...	...	...	...	...



Varje rad innehåller en lista med genrer
(samma princip gäller för categories och tags).



MultiLabelBinarizer gör om varje unik kategori
till en egen kolumn med 0 eller 1.

- **1** = egenskapen finns i spelet
- **0** = egenskapen finns inte i spelet
- Samma process används för genres, categories och tags.
- Tags testas både som 0/1 och som tag-score.

Från alla features till modeller

Vi slår ihop alla features och testar två tree-baserade modeller.

1 Byggt slutligt dataset

```
df_final_tags = pd.concat([  
    df_base,  
    genre_encoded,  
    categories_encoded,  
    tags_encoded  
, axis=1)
```

2 Slutligt dataset

```
df_final_tags.info()  
  
RangeIndex: 29241 entries, 0 to 29240  
Columns: 125 entries  
Dtypes: bool(3), float64(1), int64(121)  
Memory usage: 27.3 MB
```

29,241
spel

125
features

3 Modeller vi testar



Random Forest

- Ensemble av decision trees
- Bra på att hantera många binära/numeriska features



XGBoost

- Gradient boosting av trees
- Kraftfull modell för tabulär data

```
model.fit(X_train, y_train)  
y_pred = model.predict(X_test)
```



Många features

125 variabler från metadata, community och gameplay.



Tree-baserade modeller

Använder alla features samtidigt för att prediktera success.

Modellresultat & inställningar

Vi jämförde Random Forest och XGBoost med optimerade hyperparametrar.


XGBoost – Classification Report

	precision	recall	f1-score	support
0	0.71	0.73	0.72	3270
1	0.65	0.62	0.63	2579
accuracy			0.68	5849
macro avg	0.68	0.68	0.68	5849
weighted avg	0.68	0.68	0.68	5849

XGBoost – Hyperparametrar

```
{
  'subsample': 1.0,
  'n_estimators': 300,
  'min_child_weight': 3,
  'max_depth': 6,
  'learning_rate': 0.1,
  'colsample_bytree': 0.8
}
```

XGBoost – Confusion Matrix (%)



Modelljämförelse

Modell	Accuracy	F1-score (klass 1 – Successful)	Precision (klass 1)	Recall (klass 1)
Random Forest	0.67	0.60	0.64	0.57
XGBoost (vald)	0.68	0.63	0.65	0.62

✓ XGBoost presterade något bättre på alla huvudmått och valdes därför som slutmodell.

**Viktiga takeaways**

Modellen fångar 61.8% av faktiska succéer (recall) och 73.7% av icke-succéer (specificitet).

Båda modellerna presterar relativt lika – skillnaden är liten (~0.01 i accuracy).

Resultaten indikerar att metadata ensamt har begränsad prediktionskraft för kommersiell framgång.

9 FEATURE IMPORTANCE (XGBOOST)


Vilka features betyder mest?

Vi analyserar modellens viktigaste signaler med två metoder.




Top Feature Importance – XGBoost

Baserat på hur ofta en feature används för att göra split i träden.



Permutation Importance – XGBoost

Baserat på hur mycket modellens prestanda försämras när en feature slumpas.



Insikter

- Community-drivna features som **Family Sharing**, **Steam Trading Cards** och **In-App Purchases** verkar bidra mer än många genres.
- Pris** och vissa gameplay-tags (t.ex. Massively Multiplayer, tag_2D, tag_Cute) påverkar också modellen.
- Ingen enskild feature är särskilt dominant. Det tyder på att spelreception påverkas av **många mindre signaler tillsammans** snarare än en avgörande faktor.

PCA & Regression (bonus)

Vi testade linjär regression (utan klassifikation) och PCA på våra features.



Linjär regression

Modellen förutsäger positiv spelrecension (kontinuerligt).

MAE	9.85
RMSE	12.89
R^2	0.26



$R^2 \approx 0.26$


Regression fungerade sämre än klassificering.



PCA (dimensionsreduktion)

PCA reducerar dimensionaliteten i våra features.

Detta visar hur informationen i feature-datan är fördelad.



- ~40 komponenter förklarar ~70% av variansen i våra features.
- ~90 komponenter förklarar ~95% av variansen i våra features.

Informationen är utspridd över många dimensioner, ingen enskild dimension dominerar.



Viktig takeaway

PCA beskriver strukturen i våra features – inte hur väl modellen förutspår framgång. Det tyder på att signalen för "success" är utspridd över många svaga samband.



STEAM®

steam® är ett varumärke som tillhör Valve Corporation.

Sammanfattning & affärsnytta

Vi hittade vissa mönster i Steam-data, men spelreception är svårt att förutsäga exakt.



Vad modellen visar

- **Community-drivna features** verkar bidra mer än exempelvis genres eller speltyper.
- Features som **Family Sharing**, **Steam Trading Cards**, **In-App Purchases** och **Achievements** hade något större betydelse i modellen.



Family
Sharing



Steam
Trading Cards



In-App
Purchases



Achievements



Modellen kan hjälpa företag att undersöka vilka typer av community- och plattformsfunktioner som verkar bidra mer i Steam-data.



Viktiga begränsningar



Många små faktorer

Många små signaler verkar samverka.



Viktiga delar syns inte i data

Gameplay-kvalitet, innovation, timing, marknadsföring, streamer-effekt och hur kul spelet är är svårt att mäta i metadata.



Modest predictionskraft

Modellen är bättre än slumpen, men långt ifrån perfekt.



Slutsats

Modellen fungerar som ett analysverktyg för att förstå mönster i Steam-data, men mänskliga beslut och spelkvalitet är fortfarande avgörande.