

SUPERVISED LEARNING – ITERATION 1

Kan väder hjälpa till att förklara turism?

Supervised learning på väder + turistdata

NICKLAS THEGERSTRÖM
EMIL SJÖKVIST
FREDRIK KÄLL

Hypotes 1: Väder förutsäger turistflöden

Vår första intuition

- Bra väder borde dra turister
- Dåligt väder borde minska antalet
- Tydlig kausal mekanism

På pappret ett bra regressionsproblem!

Datasetet

Dataset: Svensk turismdata per region och månad
Guest nights + vädervariabler

Mål: prediktera antal besökare

Metod: Linjär regression

Första modellen: svag signal

R^2

0,12

Förklarad varians

BLANDADE P-VÄRDEN

OLS Regression Results						
Dep. Variable:	log_guest_nights	R-squared:	0.120			
Model:	OLS	Adj. R-squared:	0.117			
Method:	Least Squares	F-statistic:	46.35			
Date:	Thu, 07 May 2026	Prob (F-statistic):	4.35e-28			
Time:	01:11:55	Log-Likelihood:	-1519.8			
No. Observations:	1028	AIC:	3048.			
Df Residuals:	1024	BIC:	3067.			
Df Model:	3					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	11.6811	0.125	93.471	0.000	11.436	11.926
temp_mean	0.0426	0.007	6.309	0.000	0.029	0.056
sunny_days	0.0065	0.006	1.061	0.289	-0.006	0.019
rain_days	0.0376	0.010	3.671	0.000	0.018	0.058
Omnibus:	22.033	Durbin-Watson:	2.014			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	22.819			
Skew:	-0.352	Prob(JB):	1.11e-05			
Kurtosis:	2.805	Cond. No.	71.3			

Linjär regressesjon på alla regioner.

Svag signal

Datan kunde inte förklara turismen.

Justerade features: begränsat till sommarregioner bäst resultat

R^2

0,33

Förklarad varians

	features	r2	adj_r2	aic
67	temp_mean, sunny_days, total_sun_hours	0.332634	0.308512	213.720359
240	temp_mean, sunny_days, total_sun_hours, rain_sum	0.340444	0.308271	214.696159
241	temp_mean, sunny_days, total_sun_hours, rain_mean	0.339770	0.307564	214.785030
66	temp_mean, sunny_days, mean_sun_hours	0.330652	0.306459	213.978354
233	temp_mean, sunny_days, mean_sun_hours, rain_sum	0.338645	0.306383	214.933235
234	temp_mean, sunny_days, mean_sun_hours, rain_mean	0.337919	0.305622	215.028661
231	temp_mean, sunny_days, mean_sun_hours, total_s...	0.336891	0.304545	215.163568
243	temp_mean, sunny_days, total_sun_hours, usd	0.334427	0.301960	215.486346
239	temp_mean, sunny_days, total_sun_hours, rain_days	0.333726	0.301225	215.577884
11	temp_mean, sunny_days	0.317142	0.300883	213.716864

```
candidate_features = [
    "temp_mean",
    "sunny_days",
    "mean_sun_hours",
    "total_sun_hours",
    "rain_days",
    "rain_sum",
    "rain_mean",
    "eur",
    "usd",
    "nok",
    "dkk"
]
```

Fokus på sommarregioner: Gotland, Stockholm, Västra Götaland

Testat många olika feature-kombinationer

Bäst resultat: temperature, soldagar, soltimmar

R-värdet förbättrades som mest till 0,33

Split / Train: Train R = 0,39. Test R = < 0

Modellen generaliserade dåligt på ny data

Slutsats

1

Hypotesen fick svagt stöd

Vädervariabler hade marginell prediktiv kraft när säsong och region kontrollerats för.

2

Mekanismen förklarar resultatet

Hotellbokningar görs långt innan vädret är känt. Realiserat väder bör därför ha svag effekt på månadsturism.

3

Fortsatt vägval

För att demonstrera de tre metoderna under förhållanden med starkare signal, valde vi att också arbeta med Telco Customer Churn, där prediktorerna har välkända samband.

→ *Vi gick vidare till Telco Customer Churn*

SUPERVISED LEARNING – ITERATION 2

Vilka kunder kommer att lämna oss – och vad kan vi göra åt det?

Supervised learning på Telco Customer Churn

NICKLAS THEGERSTRÖM
EMIL SJÖKVIST
FREDRIK KÄLL

Datasetet

7043 kunder, 21 variabler

7 043

Kunder

21

Variabler

27%

Har churnat / sagt upp sig

```
df.info
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 7043 entries, 0 to 7042
Data columns (total 21 columns):
#   Column                Non-Null Count  Dtype
---  -
0   customerID            7043 non-null   object
1   gender                7043 non-null   object
2   SeniorCitizen         7043 non-null   int64
3   Partner               7043 non-null   object
4   Dependents            7043 non-null   object
5   tenure                7043 non-null   int64
6   PhoneService          7043 non-null   object
7   MultipleLines         7043 non-null   object
8   InternetService       7043 non-null   object
9   OnlineSecurity        7043 non-null   object
10  OnlineBackup          7043 non-null   object
11  DeviceProtection      7043 non-null   object
12  TechSupport           7043 non-null   object
13  StreamingTV           7043 non-null   object
14  StreamingMovies       7043 non-null   object
15  Contract              7043 non-null   object
16  PaperlessBilling       7043 non-null   object
17  PaymentMethod         7043 non-null   object
18  MonthlyCharges        7043 non-null   float64
19  TotalCharges          7043 non-null   object
20  Churn                 7043 non-null   object
dtypes: float64(1), int64(2), object(18)
```


```
df.describe
SeniorCitizen    tenure    MonthlyCharges
count  7043.000000  7043.000000  7043.000000
mean      0.182187   32.372189   36.793189
std       0.388112   24.559421   30.490417
min       0.000000    0.000000   12.250000
25%       0.000000    9.000000   15.500000
50%       0.000000   29.000000   29.750000
75%       0.000000   55.000000   47.500000
max       1.000000   72.000000  118.750000

df.head
customerID  gender  SeniorCitizen  Partner  Dependents  tenure  PhoneService \
0  7048-WM60  Female              0      Yes         No      1      No
1  6576-WM60  Male              0      No          No      34      Yes
2  3668-OPW0  Male              0      No          No      7      Yes
3  7790-WO60  Male              0      No          No      45      No
4  9237-WO10  Female             0      No          No      2      Yes

MultiLines  InternetService  OnlineSecurity  ...  DeviceProtection \
0  No phone service        DSL              No ...                No
1  No                     DSL              Yes ...                Yes
2  No                     DSL              Yes ...                No
3  No phone service        DSL              Yes ...                Yes
4  No                     No fiber optic    No ...                No

TechSupport  StreamingTV  StreamingMovies  Contract  PaperlessBilling \
0  No                No      No Month-to-month  Yes
1  No                No      No One year        No
2  No                No      No Month-to-month  Yes
3  Yes               No      No One year        No
4  No                No      No Month-to-month  Yes

PaymentMethod  MonthlyCharges  TotalCharges  Churn
0  Electronic check    29.85      29.85      No
1  Mailed check       36.39     389.9      No
2  Mailed check       53.85     388.15    Yes
3  Bank transfer (automatic)  42.36     1866.25  No
4  Electronic check    76.78     151.45    Yes
```




Variabeltyper

18 kategoriska
(kontrakt, tjänster, demografi)


3 numeriska
(tenure, charges)

1 målvariabel (Churn = Yes/No)



Vad korrelerar med Churn?

Första kartan över vilka faktorer som spelar roll



SKYDDAR

- Lång tenure
- Two year-kontrakt
- Ingen internet-tjänst

ÖKAR RISK

- Fiber-internet
- Electronic check
- Höga avgifter

Logistisk regression

Vår första modell

0.29

Pseudo R²

0.85

ROC-AUC

0.61

F1 (Churn)

Vad modellen säger

Top 3 RISK

InternetService_Fiber +2.40
 StreamingMovies +0.94
 StreamingTV +0.84
 MultipleLines +0.62
 PaperlessBilling +0.41

Top 3 SKYDD

InternetService_No -2.66
 tenure -1.39
 Contract_Two year -1.34
 Contract_One year -0.73
 Dependents -0.26

Optimization terminated successfully.
 Current function value: 0.412899
 Iterations 6

Logit Regression Results

Dep. Variable:	Churn	No. Observations:	4938
Model:	Logit	Df Residuals:	4906
Method:	MLE	Df Model:	23
Date:	Thu, 07 May 2026	Pseudo R-squ.:	0.2863
Time:	05:39:39	Log-Likelihood:	-2835.6
converged:	True	LL-Null:	-2852.2
Covariance Type:	nonrobust	LLR p-value:	0.000

	coef	std err	z	P> z	[0.025	0.975]
const	-3.9388	1.514	-2.602	0.009	-6.904	-0.972
SeniorCitizen	0.0523	0.037	1.404	0.160	-0.021	0.125
tenure	-1.3948	0.182	-7.642	0.000	-1.752	-1.036
MonthlyCharges	-2.0902	1.135	-1.842	0.065	-4.314	0.134
TotalCharges	0.7165	0.192	3.738	0.000	0.341	1.092
gender_Male	0.0294	0.078	0.379	0.705	-0.123	0.182
Partner_Yes	-0.0058	0.093	-0.062	0.950	-0.188	0.176
Dependents_Yes	-0.2636	0.108	-2.440	0.014	-0.475	-0.053
PhoneService_Yes	0.9025	0.766	1.178	0.239	-0.599	2.404
MultipleLines_Yes	0.6244	0.210	2.977	0.003	0.213	1.035
InternetService_Fiber optic	2.3962	0.946	2.532	0.011	0.542	4.251
InternetService_No	-2.6577	0.954	-2.786	0.005	-4.527	-0.788
OnlineSecurity_Yes	-0.0894	0.212	-0.421	0.674	-0.506	0.327
OnlineBackup_Yes	0.1445	0.206	0.700	0.484	-0.260	0.549
DeviceProtection_Yes	0.2761	0.209	1.321	0.187	-0.134	0.686
TechSupport_Yes	-0.0325	0.215	-0.151	0.880	-0.453	0.388
StreamingTV_Yes	0.8417	0.306	2.182	0.029	0.086	1.598
StreamingMovies_Yes	0.9386	0.388	2.420	0.016	0.178	1.699
Contract_One year	-0.7298	0.130	-5.623	0.000	-0.984	-0.475
Contract_Two year	-1.3422	0.205	-6.536	0.000	-1.745	-0.940
PaperlessBilling_Yes	0.4083	0.090	4.558	0.000	0.233	0.584
PaymentMethod_Credit card (automatic)	-0.0027	0.137	-0.239	0.811	-0.301	0.236
PaymentMethod_Electronic check	0.3774	0.113	3.341	0.001	0.156	0.599
PaymentMethod_Mailed check	0.0914	0.138	0.663	0.507	-0.179	0.361


Confusion Matrix:

		Actual: Kvar	Actual: Churn
Predicted: Kvar	1395	157	
Predicted: Churn	248	313	

Confusion Matrix - Modell 1 (med TotalCharges)

		Actual: Kvar	Actual: Churn
Predicted: Kvar	1395	157	
Predicted: Churn	248	313	

KNN – avståndsbaserad jämförelse



KNN optimal tröskel (Youden's J): 0.300

KNN (k=20, tröskel 0.300):

```
[[1043 509]
 [ 99 462]]
```

	precision	recall	f1-score	support
Kvar	0.91	0.67	0.77	1552
Churn	0.48	0.82	0.60	561
accuracy			0.71	2113
macro avg	0.69	0.75	0.69	2113
weighted avg	0.80	0.71	0.73	2113

Slutlig jämförelse:

	Accuracy	Precision	Recall	F1
Modell 1 (med TotalCharges, tröskel 0.5)	0.808	0.666	0.558	0.607
Modell 2 (utan TotalCharges, tröskel 0.5)	0.800	0.648	0.542	0.590
Modell 1 (Youden tröskel ≈ 0.25)	0.736	0.502	0.824	0.624
KNN (k=20, tröskel 0.5)	0.797	0.636	0.549	0.589
KNN (k=20, Youden ≈ 0.30)	0.712	0.476	0.824	0.603

	ROC-AUC
Modell 1 (med TotalCharges, tröskel 0.5)	0.845
Modell 2 (utan TotalCharges, tröskel 0.5)	0.842
Modell 1 (Youden tröskel ≈ 0.25)	0.845
KNN (k=20, tröskel 0.5)	0.825
KNN (k=20, Youden ≈ 0.30)	0.825

Logistisk regression vs KNN

Mått	Logistisk regression	KNN k=20
Accuracy	0.81	0.80
Precision	0.67	0.64
Recall	0.56	0.55
F1	0.61	0.59
ROC-AUC	0.85	0.83

Varför Logistik regression vinner

- 23 dimensioner – KNN trivs i låg dimensionalitet
- Mest binära features – avstånd blir grovkorniga
- LR har inte detta problem

Tröskeloptimering LR – det viktigaste valet (Youden's J)

FÖRE · Tröskel 0.5

56%

Recall för Churn-klassen

Vi hittar bara 313 av 561 churn-kunder.
248 missade.

EFTER · Tröskel 0.246 (Youden)

82%

Recall för Churn-klassen

Vi hittar 462 av 561.
149 fler räddningar.

Affärsvärde: +149 räddade kunder, kostnaden blir 301 falsklarm

...på vår testdata med 2 113 kunder. På hela kundbasen blir effekten dramatiskt större.

Klassificering svarar på "vem". Survival svarar på "när".

KLASSIFICERING

Kommer kund X säga upp avtal?

- y = binär (0/1)
- Output: sannolikhet
- Ignorerar tid
- Modeller: LR, KNN

SURVIVAL ANALYSIS

När – och hur snabbt – churnar kunder?


- y = tid + händelse
- Output: överlevnadskurva + HR
- Hanterar censurering
- Modeller: Kaplan-Meier, Cox




Vår data har redan tiden inbyggd: tenure (månader) + Churn (händelse)

Survival analysis

Kaplan-Meier: överlevnadskurva för alla kunder




Fiber-kunder uppdelade efter pris




LOG-RANK TEST

 $p < 0.0$ *Skillnaden är signifikant.*

Kaplan-Meier: överlevnad per Internet Service



Two year-kunder: vad händer vid månad 24?



Slut

TEKNISKT

Modellval

Logistisk regression bättre än KNN för dummy-tunga features.

Tröskeln ger större förbättring än modellvalet

Recall 56% → 82% bara genom Youden's J.

Kombination med PCA förbättrade inte

Vår data hade signal i alla 23 dimensioner.

AFFÄRSMÄSSIGT

Bundling > enskild teknik

Pusha tilläggstjänster på fiber-kunder.

Konvertera till långa kontrakt

Inlåsning + selektion + 24 mån att vinna lojalitet.

Push autogiro

Electronic check är konsekvent risk-markör.